

模型微调：训练保险领域的需求分析模型

一、我们要解决什么问题？

场景描述

在日常工作中，我们会收到大量的**寿险需求规格说明书**（简称"需规"）。拿到一份需规之后，业务人员需要做一系列分析工作：

- 这份需求涉及哪些保险实体？（投保人、被保人、受益人、险种、给付责任.....）
- 这些实体之间是什么关系？（投保人购买了什么险种、险种包含哪些给付责任.....）
- 这些内容和我们已有的知识体系怎么对得上？

换句话说，就是把一份"自然语言写的需求文档"，**翻译成**一套"结构化的、标准化的分析结果"。

现状痛点

痛点	具体表现
慢	一份复杂的寿险需规，人工分析可能需要几天
容易漏	人工阅读长文本，难免遗漏某些条款细节
标准不统一	不同人分析同一份需规，输出结果的格式和深度可能完全不一样

我们的目标

让 AI 自动完成这个"翻译"工作——输入一份寿险需规，输出标准化的结构化分析结果。

二、为什么通用 AI 做不了这件事？

一个类比

假设你招了一个刚毕业的高材生：

- 他**智商很高**，语言能力一流，什么文章都能读懂
- 但他**从没接触过保险行业**，不知道什么是"现金价值"、"复效期"、"减额交清"
- 他更不知道我们内部有一套叫**"本体"**的知识规范体系

你直接把一份寿险需规丢给他，让他按规范输出分析结果——他只会用大白话跟你聊，甚至会一本正经地胡编乱造。

通用 AI 的问题

能力	通用 AI 的表现
语言理解	很强，读得懂中文

能力	通用 AI 的表现
保险专业知识	很弱，不懂行业术语和业务逻辑
输出格式规范	不稳定，即使你反复强调"请输出标准格式"，它依然会跑偏

核心矛盾

它有智商，但没有行业手艺。

所以我们需要一种方法，教它学会这门手艺。这个方法就是——**微调**。

三、那怎么教它？——微调是什么？

核心概念

微调 (Fine-Tuning)，简单说就是：在一个已经训练好的通用 AI 模型基础上，用特定的"教材"再训练一遍，让它学会某种特定的行为方式。

一个类比：入职培训

还是那个高材生的比喻：

阶段	做什么	说明
大学教育	预训练	AI 模型出厂前的"通用教育"，让它学会语言和常识
入职培训	微调	拿出《优秀员工工作案例集》，手把手教它怎么干活

通过几千次的规范训练，这个高材生的工作习惯、思维链条、输出格式被扭转成一个符合业务规范的"专才"。

关键澄清

微调不是让 AI 去"背诵"保险条款，而是教它"做事的方法"。

错误理解	正确理解
把所有寿险条款塞进 AI 脑子里	教 AI 一套"看到需求→怎么拆解→怎么输出"的思维范式
让它记住每一份文档	让它学会按规范格式处理任何新文档

打个比方：你不需要厨师背下整本菜谱，你只需要教会他"切菜、控火、调味"的手艺，他就能应对各种新菜式。

四、微调有哪三种主流方向？

目前业界主流的微调方式有三种，它们各司其职，解决不同层面的问题。

4.1 CPT —— 继续预训练（让它多读专业书）

类比：让大学生去读保险专业的研究生。

维度	说明
干什么	让 AI 大量阅读寿险条款、保险法规、精算术语等专业文本
数据形式	纯文本，不需要人工编写问答（直接把文档丢给它读）
解决什么问题	扩充行业常识——让它从"外行"变成"对保险有基本认知"
比喻	大学生去读研，补专业背景知识
适用场景	当基座模型对行业术语理解不足时，推荐先用 CPT 补充专业知识

训练数据集长什么样？

CPT 的数据最简单——就是**纯文本**，不需要任何人标注。直接把专业文档丢给 AI 读就行。

数据来源	示例
FIBO 本体文档	"Financial Industry Business Ontology (FIBO) defines InsurancePolicy as a contract between an insurer and policyholder..."
寿险条款原文	"定期寿险的观察期为180天，观察期内因疾病身故仅退还已交保费，观察期后身故按基本保额给付身故保险金..."
保险法规	"根据《保险法》第十六条，投保人故意不履行如实告知义务的，保险人对于合同解除前发生的保险事故，不承担赔偿或者给付保险金的责任..."
公司内部需规	"需求编号：REQ-LIFE-2024-0032。功能描述：新增保单贷款功能，贷款金额上限为保单现金价值的80%..."

类比：就像给学生塞了一摞专业课本和公司内部资料，让他自己读，不用出考题。

4.2 SFT —— 有监督微调（手把手教它干活）

类比：带新人做项目，给标准答案照着学。

维度	说明
干什么	用"问题→标准答案"的问答对，教会 AI 怎么处理需求文档
数据形式	一问一答，需要人工精心编写（比如：输入一段需规，输出标准分析结果）
解决什么问题	学会"听指令、按规矩干活"——从会说大白话变成能输出规范格式
比喻	带着新人做项目，做一步教一步，手把手示范
适用场景	业界使用率最高的微调方式，适合需要教会 AI 特定行为模式和输出格式的场景

训练数据集长什么样？

SFT 的数据是**一问一答**，每一组都包含"输入"和"标准输出"。为了让 AI 学会思考过程，我们还会在中间加上"解题步骤"（这叫思维链，CoT）。

一组完整的训练数据包含三个部分：

【题目】（Instruction + Input）

"请分析以下寿险需规文本，提取核心实体，映射到本体类中，以标准 markdown 格式输出。"

需求文本：定期寿险产品要求投保人在投保时如实告知健康状况，观察期为**180**天。
观察期内因疾病身故仅退还已交保费；观察期后身故按基本保额给付身故保险金。
保单犹豫期为**15**天，犹豫期内可全额退保。

【解题步骤】（Thought）

第一步：识别核心实体——"投保人"、"定期寿险"、"观察期"、"身故保险金"、"犹豫期"

第二步：在本体中找到对应类——投保人→FIBO:InsuredParty，定期寿险→FIBO:TermLifeInsurance

第三步：梳理关系——投保人 与 定期寿险 之间是 hasPolicy 关系

第四步：整理属性——观察期=180天，犹豫期=15天

【标准输出】（Response）

[[定期寿险]]

- **本体类**：FIBO:TermLifeInsurance

- **投保人**：[[投保人]]（FIBO:InsuredParty）

- **观察期**：180天

- **犹豫期**：15天

- **给付责任**：[[身故保险金]]（FIBO:InsuranceBenefit）

- 观察期内：退还已交保费

- 观察期后：按基本保额给付

类比：就像老师批改作业——先看题目，再看解题过程，最后对标准答案。每一步都清清楚楚。

4.3 DPO —— 偏好优化（纠偏、提升质量）

类比：绩效考核，告诉它哪些回答好、哪些回答差。

维度	说明
干什么	给 AI 看"好的回答"和"差的回答"，让它学会区分好坏
数据形式	好回答 vs 坏回答的对照组
解决什么问题	减少胡说八道（幻觉），让输出更靠谱、更符合预期
比喻	绩效考核——干得好发奖金，干得差扣绩效
适用场景	适合对输出质量有极高要求的场景，如降低幻觉、调整语气、确保安全合规

训练数据集长什么样？

DPO 的数据是**三元组**——同一个问题，给一个好回答和一个坏回答，让 AI 自己对比学习。

【同一个问题】

"请分析以下定期寿险需求，映射到本体类。"

（需求文本省略...）

【好回答】（Positive — 模型应该学的）

[[定期寿险]]

- **本体类**: FIBO:TermLifeInsurance

- **观察期**: 180天

- **给付责任**: [[身故保险金]]（FIBO:InsuranceBenefit）

【坏回答】（Negative — 模型应该避免的）

"定期寿险是一种人寿保险产品，它主要提供身故保障。在这份需求中，我们可以看到有观察期和犹豫期的设定。观察期是180天，意味着在投保后的180天内如果发生身故，保险公司只会退还保费。犹豫期是15天..."

（问题：用了大白话聊天，没有按规范格式输出，缺少本体映射）


类比：就像经理拿出两份报告做对比——"这份写得好，格式标准、分析到位；那份写得差，啰嗦没重点、格式混乱。以后照好的来。"

DPO 里"坏回答"通常有这些毛病：

坏回答的典型问题	说明
用大白话聊天	没有输出规范的 Markdown 格式
本体映射错误	把"投保人"映射到了错误的类上
遗漏实体	需求里明明有"犹豫期"，输出里却没提
一本正经胡说八道	编造了需求文本里没有的内容（幻觉）

4.4 小结：三者的关系

用一个完整的类比串起来：



三种范式的关系：

范式	数据准备难度	典型数据量	推荐搭配
CPT	低（纯文本，无需标注）	几 GB 专业文档	适合行业知识补充不足时使用
SFT	中（需编写问答对）	2000~3000 条	适合需要教会 AI 特定行为模式时使用
DPO	高（需编写好/坏对照组）	1000~2000 条	适合对输出质量有极高要求时使用

业界常见实践：大多数垂直领域场景下，SFT 是基础标配；对于金融、保险等专业知识密集领域，CPT+SFT 的组合更为常见；对输出质量和安全性要求极高的产品，会在 SFT 基础上增加 DPO 环节。

五、结合寿险需求分析：我们的方案是什么？

5.1 我们的知识底座：本体 + Markdown 知识库

在讲微调怎么用之前，先了解我们的知识架构——整个系统有两大知识底座：

组件	角色	类比	说明
Protégé 本体 (TBox)	规定规则	法律	定义了保险世界的"类"（如投保人、险种、给付责任）和"关系"（如投保人购买险种），是绝对的规范
Markdown 知识库 (ABox)	存放内容	百科全书	存放着海量的寿险条款、需求文档实例，用双链（[[重疾险]]、[[等待期]]）连成一张知识网络

它们的关系：

本体是"宪法"，规定了世界怎么分类；知识库是"图书馆"，按宪法的分类存放具体知识。

5.2 微调在这里扮演什么角色？

有了本体和知识库，还需要微调干什么？

答案是：需要一个"操作员"来连接它们。

类比说明：

你有一本法律大全（本体）和一个巨大的图书馆（知识库），但你需要一个专业的图书管理员——他知道怎么根据问题去图书馆里查资料，查完之后怎么按照法律的分类标准整理出来。


微调，就是培养这个"图书管理员"。

具体来说，微调教会 AI 三样本事：

本事	说明	类比
本体感知	读到需求时，本能地找到对应的本体类（如 <code>FIBO:InsuredParty</code> ）和属性（如 <code>hasPremium</code> ）	图书管理员看到书名就知道该放到哪个分类架上
知识关联	熟练使用 Markdown 双链语法，把分析结果和已有知识节点关联起来	知道这本书和那本书之间有引用关系，主动建立索引
格式纪律	输出永远是标准的、可直接被程序解析的 Markdown 格式	填表永远按模板来，绝不乱写

5.3 完整工作流程

把整个流程串起来：





类比：就像给工厂装了一条自动化生产线——原料（需求文档）进来，标准产品（结构化分析结果）出去。

六、具体怎么落地？

围绕竞赛总纲的任务 C，我们分成两步走：

6.1 任务 C-a：训练数据集准备

类比：根据不同的"培训方式"，编写不同类型的教材。

前面介绍了三种微调范式，每种范式需要的数据格式不同。下面分别说明。

6.1.1 CPT 数据集——"专业课本"

类比：给学生准备一摞专业课本和参考资料，让他自己读。

维度	说明
数据格式	纯文本，无需人工标注
数据来源	FIBO 本体文档、寿险条款原文、保险法规、公司内部需规
典型数据量	几 GB 的专业文本
制作难度	最低——直接收集现有文档即可

数据示例：

【FIBO 本体文档片段】

Financial Industry Business Ontology (FIBO) defines InsurancePolicy as a contract between an insurer and a policyholder, specifying the terms and conditions of coverage...

【寿险条款原文】

定期寿险的观察期为180天，观察期内因疾病身故仅退还已交保费，观察期后身故按基本保额给付身故保险金...

【公司内部需规】

需求编号：REQ-LIFE-2024-0032。功能描述：新增保单贷款功能，贷款金额上限为保单现金价值的80%...

6.1.2 SFT 数据集——"真题及详解"

类比：编写一本《岗位操作手册及真题详解》，每道题都有标准答案和解题步骤。

维度	说明
数据格式	思维链问答对（题目 → 解题步骤 → 标准答案）
数据来源	专家编写 + AI 扩增 + 自动校验 + 专家精修
典型数据量	2000~3000 条
制作难度	中等——需要精心设计问答对

一组完整的 SFT 数据包含三个部分：

部分	内容	类比
题目	一段寿险需求文本 + 指令	考试卷上的题目
解题步骤	AI 应该怎么一步步思考（思维链）	标准答案的"解题过程"
标准答案	符合规范的结构化 Markdown 输出	最终得分点

三类题型均衡配置：

题型	内容	目的	建议占比
题型 A	需求文本 → 本体映射	学会识别保险实体，对到本体类上	~30%
题型 B	需求文本 → Markdown 知识网络	学会用双链把分析结果织入知识库	~30%
题型 C	需求场景 → 结构化评估	学会做功能拆解、冲突检查、工作量预估	~30%

SFT 数据生产流程：

步骤	做什么	数量
第一步	专家亲自编写"教科书级"完美范例	~50 条种子数据
第二步	用强大的 AI 模型学习范例，批量仿写	扩增至 2000~3000 条
第三步	程序自动检查格式合法性（括号配对、类名是否存在等），不合格的淘汰	自动过滤
第四步	专家抽样检查，修正业务逻辑错误	精修定稿

关键原则：1000 条高质量数据，远好于 10000 条粗制滥造的数据。质量永远比数量重要。

6.1.3 DPO 数据集——"好报告 vs 坏报告"

类比：经理拿出两份报告做对比，告诉员工哪份写得好、哪份写得差。

维度	说明
数据格式	三元组（同一个问题 + 好回答 + 坏回答）
数据来源	好回答来自 SFT 标准答案，坏回答由人工或 AI 刻意构造
典型数据量	1000~2000 条
制作难度	最高——需要同时编写好/坏两组回答，且"坏"得要有代表性

一组完整的 DPO 数据包含三个部分：

部分	内容	说明
问题	一段需求文本	三种范式共用的输入
好回答 (Positive)	符合规范的结构化输出	AI 应该学会的
坏回答 (Negative)	有典型毛病的输出	AI 应该避免的

"坏回答"的典型毛病：

问题类型	具体表现
用大白话聊天	没有输出规范的 Markdown 格式，而是写了一段散文
本体映射错误	把"投保人"映射到了错误的本体类上
遗漏实体	需求里明明有"犹豫期"，输出里却没提
胡说八道	编造了需求文本里没有的内容（幻觉）

6.1.4 三种数据集对比总结

维度	CPT 数据	SFT 数据	DPO 数据
类比	专业课本	真题及详解	好报告 vs 坏报告
格式	纯文本	思维链问答对	好/坏回答三元组
需要标注	否	是	是
制作难度	低	中	高
典型数据量	几 GB	2000~3000 条	1000~2000 条

6.2 任务 C-b：小基座模型微调

类比：培养一个"打下手的实习生"，帮教授（大模型）准备材料、做预处理。

什么是"小基座模型"？


类型	参数量	类比	代表
大模型	700亿+	全能教授，理解力强，但身价高、速度慢	GPT-4、Claude
小基座模型	70~140亿	精干的实习生，聪明、便宜、手脚麻利	Qwen2.5-7B、Llama-3.1-8B


小基座模型在系统中的角色——"助手"而非"主角"

在实际的需求分析流程中，小基座不是最终输出分析结果的那个"专家"，而是**帮大模型打下手的助手**。具体承担三类工作：

角色	做什么	类比
数据标注助手	把原始需规文本初步标注成结构化数据，给大模型微调准备教材	帮老师批改选择题的课代表
数据扩增助手	学习专家写的 50 条种子范例，批量仿写几千条训练数据	照着样卷誊写练习题的学委
预处理工具	对需求文档做初步的实体识别和文本分类，减轻大模型负担	公司前台，先初筛访客，只让重要的进去见老板

完整的工作流：小基座 + 大模型协同





为什么选小模型来做助手？

优势	说明	类比
省钱	只需要一张普通显卡就能运行，不需要昂贵的服务器集群	实习生工资低，养得起
安全	可以完全在内部网络运行，数据不出门	在自己公司培训，不用担心商业机密外泄
快	推理速度快，批量处理数据时效率极高	手脚麻利，干杂活效率高
可微调	体量小，微调成本低，可以快速定制专属的数据标注和预处理能力	实习生可塑性强，教什么学什么

怎么微调小基座？

方法	做什么	什么时候用
SFT	用精心准备的教材教它学会数据标注和预处理的手艺	核心步骤
CPT	如果它连基础保险术语都不认识，先让它读大量专业书补补课	视情况而定

微调后的效果

微调前	微调后
不认识保险术语和本体类	能初步识别需求文本中的保险实体
输出格式随心所欲	标注数据时格式标准、规范
需要长长提示词才能干活	简单指令就能高效完成数据预处理任务
批量处理效率低	可以快速处理大量需规，为大模型备好"半成品"

七、总结

用一句话说清楚整个方案：

我们用大模型做最终的需求分析，同时用小基座模型做数据准备和预处理，两者协同工作。

整个方案的核心逻辑：

本体（规矩） + 知识库（资料） + 小基座（助手预处理）+ 大模型（专家出结果）= 自动化需求分析

组件	角色	一句话
Protégé 本体	规定规矩	告诉 AI 保险世界怎么分类、关系怎么定义
Markdown 知识库	提供资料	存放海量条款和需规，供 AI 随时查阅
训练数据集	培训教材	教小基座学会数据标注和预处理的手艺
小基座模型	打下手的助手	负责数据标注、扩增、预处理，帮大模型备好材料
大模型	最终专家	接收预处理结果，结合本体和知识库，输出最终需求分析